In [1]:

```
import pandas as pd
import numpy as np
from datetime import datetime
from tqdm import tqdm
import matplotlib.pyplot as plt
```

In [2]:

```
data = pd.read_csv('training.csv')
data.head()
```

Out[2]:

	customer_id	visit_date	visit_spend
0	2	2010-04-01	5.97
1	2	2010-04-06	12.71
2	2	2010-04-07	34.52
3	2	2010-04-12	7.89
4	2	2010-04-14	17.17

In [ ]:

```

```

In [ ]:

```

```

In [7]:

```
def TopHat(x):
    return 0.5*(abs(x)<10)
def KDE(kernel, w, width, observable_points,  x):
    summ = 0
    for i in range(len(observable_points)):
        summ += w[i]*TopHat((x - observable_points[i])/width)
    return summ
```

In [8]:

```
start_train = datetime.strptime('2010-04-05', '%Y-%m-%d').date()
end_train = datetime.strptime('2011-05-29', '%Y-%m-%d').date()
```

In [13]:

```
customers = sorted(np.unique(data['customer_id']))
```

In [14]:

```
data_train = data[(data['visit_date'] < '2011-05-30') & (data['visit_date'] >= '2010-04-05'
data_test = data[data['visit_date'] >= '2011-05-30']
```

За y_true взята сумма покупки в предполагаемый первый день визита из исследования Павла Лукьяненко.

In [16]:

```
y_true = []
y1_true = []
for client in tqdm(customers):
    cur_data = data_test[(data_test['customer_id'] == client)]
    visit = np.array(cur_data[['visit_date','visit_spend']]).T
    if visit.shape[1] > 0:
        minind = visit[0].argmin()
        first_visit = visit[0][minind]
        if (datetime.strptime(first_visit, '%Y-%m-%d').date() - end_train).days < 7:
            y_true.append(datetime.strptime(first_visit, '%Y-%m-%d').date().weekday())
            y1_true.append(visit[1][minind])
        else:
            y_true.append(-1)
            y1_true.append(-1)
    else:
        y_true.append(-1)
        y1_true.append(-1)
```

```
100%|██████████████████████████████████████████████████████████████████████
█| 100000/100000 [03:46<00:00, 441.56it/s]
```

Для каждого клиента создается два элемента:

1. Массив всех его сумм покупок за все время в train (далее отсортированные).
2. Суммы покупок в предсказываемый день недели.

В первом из лекции - это $s_1, \ldots, s_m$, второе - $s'_1, \ldots, s'_{m'}$

In [18]:

```
customers_spend_concat = []
for client in tqdm(range(len(customers))):
    cur_data = data_train[(data_train['customer_id'] == customers[client])]
    visit = np.array(cur_data[['visit_date','visit_spend']]).T
    m_array = []
    for date in range(len(visit[0])):
        if (datetime.strptime(visit[0][date], '%Y-%m-%d').date() - start_train).days % 7 ==
            m_array.append(visit[1][date])
    customers_spend_concat.append([visit[1], m_array])
```

```
100%|██████████████████████████████████████████████████████████████████████
██| 100000/100000 [32:31<00:00, 51.25it/s]
```

In [ ]:

```
```

In [19]:

```
for client in tqdm(range(len(customers))):
        customers_spend_concat[client][1] = set(customers_spend_concat[client][1])
        customers_spend_concat[client][0] = np.sort(customers_spend_concat[client][0])
```

```
100%|██████████████████████████████████████████████████████████████████████████████|
100000/100000 [00:02<00:00, 39062.57it/s]
```

Высчитывается весовая схема $f(x) = \sum_{i=1}^{m} \omega_i * K(|s_i - x|)$

$\omega_i = (1 - \beta)\frac{(m-i-1)^\rho}{\sum_{j=1}^{m} j^\rho} \leftrightarrow s_i$

$\omega_i = \beta\frac{(m^{'}-i-1)^\rho 1}{\sum_{j=1}^{m^{'}} j^{\rho 1}} \leftrightarrow s_i^{'}$

In [20]:

```
# ro1 = 1
# ro2 = 1
def predict(customers_spend_concat, beta, p0, p1):
    y1_pred = []
    s = np.sum(np.arange(len(customers))**p1)
    for client in tqdm(range(len(customers))):
        observable_points = customers_spend_concat[client][0]
        set_cust = customers_spend_concat[client][1]
        w = np.array([(1 - beta)*(len(customers) - i + 1)**p1 / s for i in range(len(observ
        k = np.sum(np.arange(len(set_cust))**p0)
        if k > 0:
            for i in range(len(observable_points)):
                if observable_points[i] in set_cust:
                    w[i] += (beta)*(len(set_cust) - i + 1)**p0 / k
        x_axis = np.arange(np.min(customers_spend_concat[client][0]), np.max(customers_spen
        res = np.array(list(map(lambda x: KDE(TopHat, w, 10, observable_points, x), x_axis)
        y1_pred.append(x_axis[res.argmax()])
    return y1_pred
```

In [21]:

```
def score(y_true, y_pred):
    return (abs(np.array(y_true) - np.array(y_pred)) <= 10).sum() / len(y_true)
```

In [22]:

```
# x_axis[res.argmax()]
```

In [23]:

```
betas = [0, 0.2, 0.6, 0.8, 1]
res_beta = []
for i in range(len(betas)):
    res_beta.append(score(predict(customers_spend_concat, betas[i], 1,1), y1_true))
    print(betas[i], res_beta[i])
```

```
100%|████████████████████████████████████████████████████████████████
██| 100000/100000 [49:21<00:00, 33.77it/s]
  0%|
| 9/100000 [00:00<41:49, 39.84it/s]

0 0.18823

100%|████████████████████████████████████████████████████████████████
██| 100000/100000 [53:42<00:00, 31.03it/s]
  0%|
| 10/100000 [00:00<35:44, 46.63it/s]

0.2 0.11816

100%|████████████████████████████████████████████████████████████████
██| 100000/100000 [48:39<00:00, 34.26it/s]
  0%|
| 6/100000 [00:00<33:19, 50.00it/s]

0.6 0.1176

100%|████████████████████████████████████████████████████████████████
██| 100000/100000 [49:05<00:00, 33.95it/s]
  0%|
| 11/100000 [00:00<36:45, 45.34it/s]

0.8 0.11756

100%|████████████████████████████████████████████████████████████████
██| 100000/100000 [48:22<00:00, 34.45it/s]

1 0.23579
```

In [24]:

```
plt.plot(betas, res_beta)
plt.xlabel('beta')
plt.ylabel('score')
plt.title('Зависимость качества прогноза от параметра beta')
plt.show()
```

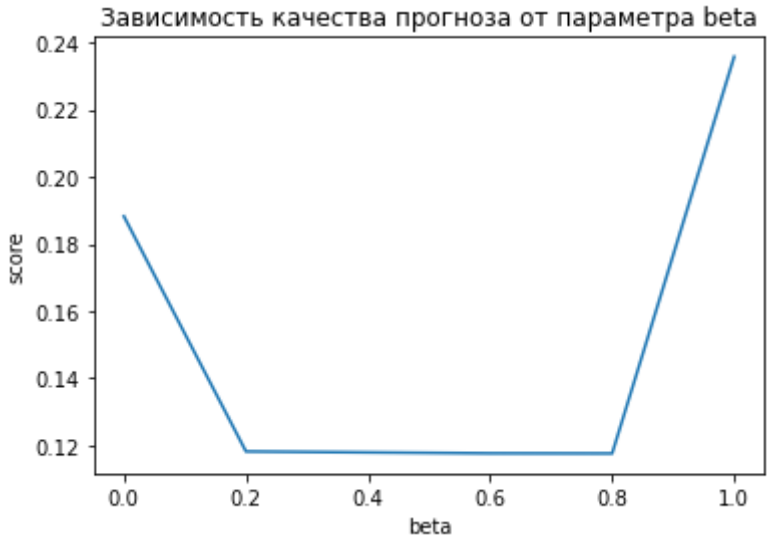

In [25]:

```
res_beta
```

Out[25]:

```
[0.18823, 0.11816, 0.1176, 0.11756, 0.23579]
```

Как видно из графика, в моем случае хорошо работает при β ,близких к нулю и к единице, то есть при использовании только данных всех сумм покупок за весь период или только сумм покупок, совершенных в угадываемый день недели.

Могу предположить, что это происходит из-за выбора predict. Было бы неплохо увеличить тестовые данные и совместить результаты на по нескольким суммам по каждому клиенту, но выполненный код очень неоптимален и демонстрирует медленную работу, что не дает выполнить дополнительные исследования

In [24]:

In [25]:

In [ ]:

In [26]: